

Riesgo de crédito de la banca privada del Ecuador

Enero - agosto 2026

Proyecto final · Dashboard EDA por profesión (sumativa 50%)

Profesión presentada: **Finanzas (análisis de riesgo de crédito)**

Integrantes: [nombre del integrante financiero] y [nombre del integrante psicólogo clínico]

Contenido del documento: 1) Contexto y datos, 2) Estructura del proyecto, 3) Parte técnica: explicación del código celda por celda, 4) Parte metodológica: EDA en 7 pasos, 5) Dashboard y decisiones, 6) Guía de ejecución y publicación, 7) Preguntas probables de la exposición.

Repositorio GitHub: [pegar enlace] | Dashboard en línea: [pegar enlace]

1. Contexto y datos

1.1 Profesión, problema y decisión

La profesión presentada es **finanzas**, en el rol de analista de riesgo de crédito de un banco privado. El problema real es que la morosidad no se reparte de forma pareja: cambia según el tipo de crédito, la zona del país y la entidad. En 2026 hay además incertidumbre por el Fenómeno de El Niño previsto para el país.

Decisión que se quiere apoyar: dónde reforzar provisiones o endurecer la política de colocación, y dónde hay espacio para ampliar la colocación con riesgo bajo.

Pregunta central: ¿qué segmentos de crédito, regiones y entidades concentran más riesgo de morosidad en la banca privada?

1.2 Origen de los datos y cómo se obtuvieron

Los datos son **reales, no simulados**. Proviene de la Superintendencia de Bancos del Ecuador, Portal Estadístico, sección *Cartera y Depósitos*, carpeta *Año 2026 / CARTERA*. Se descargaron cuatro archivos Excel de banca privada con corte a agosto de 2026: consumo, productivo, microcrédito y vivienda (esta incluye inmobiliario y vivienda de interés público).

Cada Excel trae una hoja tipo reporte (con celdas combinadas) y una hoja **BASE** en formato tabla. El proyecto usa solo las hojas BASE. El resultado es una tabla de **13.765 filas** con 24 entidades, 25 provincias y 122 cantones, mes a mes de enero a agosto.

1.3 Diccionario de variables

Variable	Descripción
segmento	Tipo de crédito: Consumo, Microcrédito, Productivo, Inmobiliario, Vivienda interés público
fecha / mes	Fecha de corte mensual y su versión AAAA-MM
entidad, provincia, canton	Banco privado y ubicación geográfica de la cartera
region	Calculada: Costa, Sierra, Oriente, Insular (según provincia)
por_vencer	Cartera al día (USD)
no_devenga	Cartera que no devenga intereses (USD)
vencida	Cartera vencida (USD)
saldo_total	Saldo total de la cartera (USD)
improductiva	Calculada: no_devenga + vencida
morosidad_pct	Calculada: improductiva / saldo_total x 100

1.4 Métrica clave

Morosidad ponderada = suma de cartera improductiva / suma de saldo total. Se usa la versión ponderada y no el promedio de porcentajes, porque un cantón con USD 2 de saldo no debe pesar igual que uno con USD 2.000 millones.

2. Estructura del proyecto

```
proyecto/
|-- app.py                dashboard en Streamlit
|-- preparar_datos.py     limpieza: data/raw -> data/processed
|-- requirements.txt      librerías necesarias
|-- README.md            descripción, datos y cómo ejecutar
|-- notebooks/
|   +-- EDA_cartera_banca_privada.ipynb    EDA en los 7 pasos
|-- data/
|   |-- raw/                4 Excel originales (Superintendencia de Bancos)
|   +-- processed/         cartera_banca_privada_2026.csv (13.765 filas)
+-- docs/                  este documento en PDF
```

Flujo: los Excel originales (data/raw) se limpian en el notebook o con preparar_datos.py y generan un único CSV (data/processed). Ese CSV lo lee el dashboard, así notebook y tablero usan exactamente los mismos datos.

3. Parte técnica: explicación del código

Esta sección sigue el notebook *EDA_cartera_banca_privada.ipynb* celda por celda. Cada bloque muestra el código y explica qué hace. El nombre de cada paso coincide con los 7 pasos del EDA del curso.

Paso 2 · Estructura (carga, limpieza y transformación)

Celda 1: Librerías y rutas

Importa las librerías (pandas y numpy para datos, matplotlib y seaborn para gráficos), define estilo y localiza la carpeta data/raw donde están los Excel originales.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from pathlib import Path
from IPython.display import display

sns.set_theme(style="whitegrid")
plt.rcParams["figure.dpi"] = 110
pd.options.display.float_format = "{:, .2f}".format

# Carpeta del proyecto (funciona ejecutando desde /notebooks o desde la raíz)
RAIZ = Path("..") if Path("../data/raw").exists() else Path(".")
RAW = RAIZ / "data" / "raw"
PROCESADO = RAIZ / "data" / "processed"
print("Archivos de entrada:")
for f in sorted(RAW.glob("*.xlsx")):
    print(" -", f.name)
```

Celda 2: Carga y unión de los 4 archivos

Lee cada libro Excel y toma únicamente las hojas que empiezan con «BASE». Usa header=1 porque el encabezado está en la segunda fila, elimina la primera columna vacía, nombra las columnas y rellena hacia abajo el segmento (ffill) porque solo está escrito en la primera fila. Une todo con pd.concat y acorta los nombres de los bancos.

```
COLUMNAS = ["segmento", "fecha", "entidad", "provincia", "canton",
            "por_vencer", "no_devenga", "vencida", "saldo_total"]

def entidad_corta(nombre):
    """Acorta los nombres de banco para que quepan en los graficos."""
    n = " ".join(nombre.split())
    if "CODESARROLLO" in n:
        return "CODESARROLLO"
    if "AMIBANK" in n:
        return "AMIBANK (liquidacion)"
    if "VISIONFUND" in n:
        return "VISIONFUND"
    return n.replace("BP ", "").replace("BANCO ", "").replace(" S.A.", "")

tablas = []
for archivo in sorted(RAW.glob("*.xlsx")):
    libro = pd.ExcelFile(archivo)
    for hoja in libro.sheet_names():
        if hoja.startswith("BASE"):
            # solo hojas en formato tabla
            t = libro.parse(hoja, header=1).iloc[:, 1:] # fila 2 = encabezado; se quita col. A vacia
            t.columns = COLUMNAS
            t["segmento"] = t["segmento"].ffill() # el segmento solo aparece en la 1a fila
            tablas.append(t)

crudo = pd.concat(tablas, ignore_index=True)
crudo["entidad"] = crudo["entidad"].map(entidad_corta)
print("Filas x columnas:", crudo.shape)
crudo.head()
```

Celda 3: Tipos de datos y dimensiones

Revisa tipos de datos, rango de fechas y cuántas entidades, provincias y cantones hay. Confirma que las fechas se leyeron como fecha y los montos como número.

```
crudo.info()
print()
print("Periodo:", crudo["fecha"].min().date(), "a", crudo["fecha"].max().date())
print("Entidades:", crudo["entidad"].nunique(),
      "| Provincias:", crudo["provincia"].nunique(),
      "| Cantones:", crudo["canton"].nunique())
print()
print(crudo["segmento"].value_counts())
```

Celda 4: Diccionario de variables

Documenta cada variable: las 9 originales y las 4 que se calculan más adelante. Sirve para explicar rápidamente los datos ante el docente.

```
diccionario = pd.DataFrame({
    "variable": COLUMNAS + ["improductiva", "morosidad_pct", "mes", "region"],
    "descripcion": [
        "Tipo de credito (consumo, microcredito, productivo, inmobiliario, vivienda interes publico)",
        "Fecha de corte mensual",
        "Banco privado",
        "Provincia",
        "Canton",
        "Cartera al dia (USD)",
        "Cartera que no devenga intereses (USD)",
        "Cartera vencida (USD)",
        "Saldo total de la cartera (USD)",
        "Calculada: no_devenga + vencida",
        "Calculada: improductiva / saldo_total x 100",
        "Calculada: mes en formato AAAA-MM",
        "Calculada: Costa, Sierra, Oriente, Insular (asignada por provincia)"]
})
display(diccionario)
```

Celda 5: Controles de integridad

Dos controles de integridad. Primero verifica que por vencer + no devenga + vencida cuadre con el saldo total (la diferencia máxima es de centavos). Segundo detecta llaves repetidas: son filas de BP Pichincha en Quito con un monto simbólico de USD 1 junto a la fila principal; se consolidan sumando porque son montos.

```
df = crudo.copy()

# Control 1: las tres partes de la cartera deben sumar el saldo total
df["cuadre"] = df["por_vencer"] + df["no_devenga"] + df["vencida"] - df["saldo_total"]
print("Diferencia maxima en el cuadre (USD):", df["cuadre"].abs().max())

# Control 2: no debe haber filas repetidas para la misma llave
llave = ["segmento", "fecha", "entidad", "provincia", "canton"]
print("Filas duplicadas en la llave:", df.duplicated(llave).sum())
display(df[df.duplicated(llave, keep=False)].sort_values(llave).head(4))

# Se consolidan sumando (son montos)
df = df.groupby(llave, as_index=False)[["por_vencer", "no_devenga", "vencida", "saldo_total"]].sum()
print("Filas despues de consolidar:", len(df))
```

Celda 6: Variables derivadas

Crea las variables de análisis: nombres legibles de segmento, la región (Costa, Sierra, Oriente, Insular) según la provincia, la cartera improductiva, la morosidad por fila y el mes. Supuesto documentado: Santo Domingo de los Tsáchilas se clasifica en Sierra; «Otros» agrupa la zona no delimitada.

```
SEGMENTOS = {"CONSUMO": "Consumo", "MICROCREDITO": "Microcrédito", "PRODUCTIVO": "Productivo",
             "INMOBILIARIO": "Inmobiliario", "VIVIENDA INTERES PUBLICO": "Vivienda interés público"}
df["segmento"] = df["segmento"].map(SEGMENTOS)

REGION = {}
for p in ["EL ORO", "ESMERALDAS", "GUAYAS", "LOS RIOS", "MANABI", "SANTA ELENA"]:
    REGION[p] = "Costa"
for p in ["AZUAY", "BOLIVAR", "CAÑAR", "CARCHI", "CHIMBORAZO", "COTOPAXI", "IMBABURA", "LOJA",
          "PICHINCHA", "SANTO DOMINGO DE LOS TSÁCHILAS", "TUNGURAHUA"]:
    REGION[p] = "Sierra"
for p in ["MORONA SANTIAGO", "NAPÓ", "ORELLANA", "PASTAZA", "SUCUMBIOS", "ZAMORA CHINCHIPE"]:
    REGION[p] = "Oriente"
REGION["GALAPAGOS"] = "Insular"

df["region"] = df["provincia"].map(REGION).fillna("Otros") # 'Otros' = zona no delimitada
df["improductiva"] = df["no_devenga"] + df["vencida"]
df["morosidad_pct"] = np.where(df["saldo_total"] > 0, df["improductiva"] / df["saldo_total"] * 100, np.nan)
df["mes"] = df["fecha"].dt.strftime("%Y-%m")

df.drop(columns="cuadre", errors="ignore", inplace=True)
df.head()
```

Celda 7: Exportar dataset limpio

Guarda el dataset limpio en data/processed. Este CSV es el que lee el dashboard de Streamlit, así notebook y tablero usan exactamente los mismos datos.

```
PROCESADO.mkdir(parents=True, exist_ok=True)
columnas_salida = ["fecha", "mes", "segmento", "entidad", "provincia", "region", "canton",
                  "por_vencer", "no_devenga", "vencida", "saldo_total", "improductiva", "morosidad_pct"]
df[columnas_salida].to_csv(PROCESADO / "cartera_banca_privada_2026.csv", index=False)
print("Guardado:", PROCESADO / "cartera_banca_privada_2026.csv", "| filas:", len(df))
```

Paso 3 · Univariado

Celda 8: Cobertura de los datos

Cuenta registros por segmento y por mes. Sirve para comprobar que la cobertura es pareja en el tiempo (aprox. 1.700 filas cada mes) y ver qué segmentos tienen más detalle geográfico.

```
fig, ax = plt.subplots(1, 2, figsize=(12, 4))
df["segmento"].value_counts().sort_values().plot.barh(ax=ax[0], color="#2a6f97")
ax[0].set_title("Registros por segmento")
df.groupby("mes").size().plot.bar(ax=ax[1], color="#2a6f97", rot=45)
ax[1].set_title("Registros por mes")
plt.tight_layout()
plt.show()
```

Celda 9: Estadísticos descriptivos

Estadísticos descriptivos (media, mediana, cuartiles, percentil 95) y asimetría. La media del saldo es muy superior a la mediana y la asimetría es alta: pocos cantones concentran casi todo el dinero.

```
resumen = df[["saldo_total", "improductiva", "morosidad_pct"]].describe(percentiles=[.25, .5, .75, .95]).T
resumen["asimetria"] = df[["saldo_total", "improductiva", "morosidad_pct"]].skew()
display(resumen)
```

Celda 10: Distribución de saldo y morosidad

Histogramas de saldo (en escala logarítmica, porque cubre desde pocos dólares hasta miles de millones) y de morosidad. La morosidad muestra picos en 0% y en 100%: son filas con saldos mínimos, lo que se trata en el paso 5.

```
fig, ax = plt.subplots(1, 2, figsize=(12, 4))
np.log10(df.loc[df["saldo_total"] > 0, "saldo_total"]).plot.hist(bins=40, ax=ax[0], color="#2a6f97")
ax[0].set_title("Saldo por fila (escala log10 de USD)")
ax[0].set_xlabel("log10(saldo)")
df["morosidad_pct"].plot.hist(bins=50, ax=ax[1], color="#e07a5f")
ax[1].set_title("Morosidad por fila (%)")
ax[1].set_xlabel("morosidad %")
plt.tight_layout()
plt.show()
```

Celda 11: Peso de cada segmento

Tabla del último mes por segmento: saldo, improductiva, morosidad ponderada y qué porcentaje del saldo y de la improductiva total aporta cada uno. Permite comparar el peso en porcentaje contra el peso en dólares.

```
ULT = df["mes"].max() # ultimo mes disponible
ago = df[df["mes"] == ULT]

seg = ago.groupby("segmento")[["saldo_total", "improductiva"]].sum()
seg["morosidad_pct"] = seg["improductiva"] / seg["saldo_total"] * 100
seg["peso_saldo_pct"] = seg["saldo_total"] / seg["saldo_total"].sum() * 100
seg["peso_improductiva_pct"] = seg["improductiva"] / seg["improductiva"].sum() * 100
print("Corte:", ULT)
display(seg.sort_values("morosidad_pct", ascending=False).round(2))
```

Celda 12: Entidades más grandes

Ranking de las 12 entidades con mayor cartera. Muestra que el sistema está concentrado en pocos bancos grandes.

```
ent = ago.groupby("entidad")[["saldo_total", "improductiva"]].sum().sort_values("saldo_total")
fig, ax = plt.subplots(figsize=(9, 6))
(ent["saldo_total"] / 1e9).tail(12).plot.barh(ax=ax, color="#2a6f97")
ax.set_title("Las 12 entidades con mayor cartera (agosto 2026)")
ax.set_xlabel("Miles de millones de USD")
plt.tight_layout()
plt.show()
```

Paso 4 · Bivariado

Celda 13: Morosidad por segmento en el tiempo

Relación tiempo-morosidad por segmento. Se agrupa por mes y segmento, se suman saldo e improductiva y se calcula la morosidad ponderada. Microcrédito y consumo se mantienen más altos que productivo e inmobiliario durante todo el periodo.

```
mes_seg = df.groupby(["mes", "segmento"])[["saldo_total", "improductiva"]].sum()
mes_seg["morosidad_pct"] = mes_seg["improductiva"] / mes_seg["saldo_total"] * 100
tabla_mes = mes_seg["morosidad_pct"].unstack()

tabla_mes.plot(figsize=(10, 4.5), marker="o")
plt.title("Morosidad ponderada por segmento y mes (%)")
plt.ylabel("%")
plt.xticks(rotation=45)
plt.legend(title="", bbox_to_anchor=(1.02, 1), loc="upper left")
plt.tight_layout()
plt.show()
```

Celda 14: Segmento x región

Mapa de calor segmento por región. Cruza dos variables categóricas con la morosidad ponderada. Ayuda a ver dónde se concentra el riesgo dentro de cada tipo de crédito. Las celdas vacías significan que no hay cartera de ese segmento en esa región.

```
hm = ago.groupby(["segmento", "region"])[["saldo_total", "improductiva"]].sum()
hm["morosidad_pct"] = hm["improductiva"] / hm["saldo_total"] * 100
plt.figure(figsize=(9, 4.5))
sns.heatmap(hm["morosidad_pct"].unstack(), annot=True, fmt=".1f", cmap="YlOrRd", cbar_kws={"label": "% morosidad"})
plt.title("Morosidad ponderada: segmento x región (agosto 2026)")
plt.xlabel("")
plt.ylabel("")
plt.tight_layout()
plt.show()
```

Celda 15: Saldo vs morosidad

Dispersión entre tamaño del saldo y morosidad. Se ve un embudo: con saldos pequeños la morosidad salta entre 0% y 100%, y con saldos grandes se estabiliza. Es evidencia de que los porcentajes de filas pequeñas son ruido, y justifica el paso 5. Se usa correlación de Spearman porque el saldo está muy sesgado.

```
plt.figure(figsize=(10, 5))
sns.scatterplot(data=ago[ago["saldo_total"] > 0], x="saldo_total", y="morosidad_pct",
               hue="segmento", alpha=0.5, s=20)
plt.xscale("log")
plt.title("Saldo vs morosidad por cantón-entidad (agosto 2026)")
plt.xlabel("Saldo (USD, escala log)")
plt.ylabel("Morosidad %")
plt.legend(bbox_to_anchor=(1.02, 1), loc="upper left", title="")
plt.tight_layout()
plt.show()

print("Correlacion de Spearman saldo-morosidad:",
      round(ago[["saldo_total", "morosidad_pct"]].corr(method="spearman").iloc[0, 1], 3))
```

Celda 16: Boxplot por segmento

Diagrama de cajas de la morosidad por segmento, sin filtrar. Los muchos puntos extremos anticipan el tratamiento de atípicos del siguiente paso.

```
plt.figure(figsize=(10, 4.5))
sns.boxplot(data=df[df["saldo_total"] > 0], x="segmento", y="morosidad_pct", color="#8ecae6")
plt.title("Distribución de la morosidad por fila y segmento (sin filtrar)")
plt.xticks(rotation=15)
plt.xlabel("")
plt.ylabel("Morosidad %")
plt.tight_layout()
plt.show()
```

Paso 5 · Faltantes y atípicos

Celda 17: Faltantes

Busca datos faltantes y valores imposibles. No hay nulos ni montos negativos. La morosidad queda como NaN solo cuando el saldo es 0, porque dividir entre cero no está definido. No se imputa nada.

```
nulos = df.isna().sum()
print("Columnas con nulos:", nulos[nulos > 0].to_dict())
print("Filas con saldo 0 (morosidad indefinida):", (df["saldo_total"] == 0).sum())
print("Valores negativos en montos:", (df[["por_vencer", "no_devenga", "vencida", "saldo_total"]] < 0).sum().sum())
```

Celda 18: Atípicos con IQR

Detecta atípicos con la regla del rango intercuartílico (IQR): se consideran atípicos los valores fuera de $Q1 - 1,5 \cdot IQR$ y $Q3 + 1,5 \cdot IQR$. Se aplica a saldo y a morosidad.

```
def limites_iqr(s):
    q1, q3 = s.quantile([0.25, 0.75])
    i = q3 - q1
    return q1 - 1.5 * i, q3 + 1.5 * i

for col in ["saldo_total", "morosidad_pct"]:
    lo, hi = limites_iqr(df[col].dropna())
    n = ((df[col] < lo) | (df[col] > hi)).sum()
    print(f"{col}: límites IQR = [{lo:,.1f}; {hi:,.1f}] -> {n} filas atípicas ({n/len(df):.1%})")
```

Celda 19: Filas de saldo mínimo

Cuantifica el problema: alrededor del 16% de las filas tiene saldo menor a USD 100 mil, pero pesan una fracción mínima del saldo total. Casi todas las filas con morosidad de 100% son de saldos diminutos. Son atípicos por tamaño, no por riesgo real.

```
MIN_SALDO = 100_000 # supuesto: menos de USD 100 mil no permite medir una tasa con sentido
pequenas = df[df["saldo_total"] < MIN_SALDO]

print(f"Filas con saldo < USD {MIN_SALDO:,}: {len(pequenas):,} ({len(pequenas)/len(df):.1%} de las filas)")
print(f"...pero solo {pequenas['saldo_total'].sum()/df['saldo_total'].sum():.3%} del saldo total")
print(f"...y {pequenas['improductiva'].sum()/df['improductiva'].sum():.3%} de la improductiva total")
print(f"Filas con morosidad >= 99.9%: {df['morosidad_pct'] >= 99.9}.sum()")
print(f"de ellas con saldo < 100 mil: {((df['morosidad_pct'] >= 99.9) & (df['saldo_total'] < MIN_SALDO)).sum()}")
```

Celda 20: Antes y después del filtro

Aplica el tratamiento y compara antes y después con boxplots. Tras filtrar por saldo mínimo, la dispersión extrema desaparece y quedan tasas comparables.

```
analisis = df[df["saldo_total"] >= MIN_SALDO].copy() # para rankings a nivel canton-entidad

fig, ax = plt.subplots(1, 2, figsize=(12, 4), sharey=True)
sns.boxplot(data=df[df["saldo_total"] > 0], x="segmento", y="morosidad_pct", color="#e07a5f", ax=ax[0])
ax[0].set_title("Antes (todas las filas)")
sns.boxplot(data=analisis, x="segmento", y="morosidad_pct", color="#8ecae6", ax=ax[1])
ax[1].set_title("Después (saldo >= USD 100 mil)")
for a_ in ax:
    a_.set_xlabel("")
    a_.tick_params(axis="x", rotation=20)
plt.tight_layout()
plt.show()
```

Paso 6 · Segmentación

Celda 21: Segmento: evolución y crecimiento

Segmentación por tipo de crédito: morosidad de enero contra agosto, variación en puntos porcentuales y crecimiento de la cartera en el periodo. Vivienda de interés público tiene un crecimiento enorme pero parte de una base muy pequeña, por lo que hay que interpretarlo con cuidado.

```
saldo_mes = df.groupby(["mes", "segmento"])["saldo_total"].sum().unstack()
cambio = pd.DataFrame({
    "morosidad_ene": tabla_mes.iloc[0],
    "morosidad_ago": tabla_mes.iloc[-1],
})
cambio["var_pp"] = cambio["morosidad_ago"] - cambio["morosidad_ene"]
cambio["crecimiento_cartera_pct"] = (saldo_mes.iloc[-1] / saldo_mes.iloc[0] - 1) * 100
display(cambio.sort_values("morosidad_ago", ascending=False).round(2))
```

Celda 22: Región: tasa y dólares

Segmentación por región, mostrando lado a lado el porcentaje y los dólares. Sirve para contrastar la hipótesis H2 (diferencias regionales). Se debe leer con ambos gráficos: una región puede tener tasa alta pero pocos dólares en juego.

```
reg = ago.groupby("region")["saldo_total", "improductiva"].sum()
reg["morosidad_pct"] = reg["improductiva"] / reg["saldo_total"] * 100
reg = reg.sort_values("morosidad_pct", ascending=False)

fig, ax = plt.subplots(1, 2, figsize=(12, 4))
reg["morosidad_pct"].plot.bar(ax=ax[0], color="#e07a5f", rot=0)
ax[0].set_title("Morosidad ponderada por región (%)")
(reg["improductiva"] / 1e6).plot.bar(ax=ax[1], color="#2a6f97", rot=0)
ax[1].set_title("Cartera improductiva por región (millones USD)")
for a_ in ax:
    a_.set_xlabel("")
plt.tight_layout()
plt.show()
display(reg.round(2))
```


Celda 23: Provincias más morosas

Ranking de las 10 provincias con más morosidad ponderada, excluyendo las de cartera muy pequeña para no comparar tasas sobre montos mínimos. La línea punteada marca el promedio del sistema.

```
PROV_MIN = 50_000_000 # solo provincias con al menos USD 50 millones de cartera
prov = ago.groupby("provincia")[["saldo_total", "improductiva"]].sum()
prov["morosidad_pct"] = prov["improductiva"] / prov["saldo_total"] * 100
top_prov = prov[prov["saldo_total"] >= PROV_MIN].sort_values("morosidad_pct", ascending=False).head(10)

fig, ax = plt.subplots(figsize=(9, 5))
top_prov["morosidad_pct"].sort_values().plot.barh(ax=ax, color="#e07a5f")
ax.axvline(ago["improductiva"].sum() / ago["saldo_total"].sum() * 100, color="k", ls="--", label="Promedio sistema")
ax.set_title("10 provincias con mayor morosidad (cartera >= USD 50 millones)")
ax.set_xlabel("Morosidad %")
ax.legend()
plt.tight_layout()
plt.show()
```

Celda 24: Matriz de riesgo por entidad

Matriz de riesgo por entidad. Cada burbuja es un banco: eje X = tamaño de cartera, eje Y = morosidad, tamaño = dólares improductivos. Los bancos se clasifican en pequeño, mediano y grande por terciles de cartera. La línea punteada es la morosidad promedio del sistema.

```
ENT_MIN = 100_000_000 # entidades con al menos USD 100 millones
en = ago.groupby("entidad")[["saldo_total", "improductiva"]].sum()
en["morosidad_pct"] = en["improductiva"] / en["saldo_total"] * 100
en = en[en["saldo_total"] >= ENT_MIN].copy()
en["tamano"] = pd.qcut(en["saldo_total"], 3, labels=["Pequeña", "Mediana", "Grande"])
prom = ago["improductiva"].sum() / ago["saldo_total"].sum() * 100

fig, ax = plt.subplots(figsize=(10, 6))
sns.scatterplot(data=en, x="saldo_total", y="morosidad_pct", size="improductiva",
               hue="tamano", sizes=(60, 900), alpha=0.6, ax=ax)
ax.axhline(prom, color="k", ls="--", lw=1)
ax.set_xscale("log")
ax.set_title("Matriz de riesgo por entidad (tamaño de la burbuja = cartera improductiva)")
ax.set_xlabel("Cartera total (USD, escala log)")
ax.set_ylabel("Morosidad %")
desplazamientos = [(8, 8), (10, 30), (-90, -28), (12, -22), (8, 8), (8, 8)] # evita que se superpongan
top6 = en.sort_values("improductiva", ascending=False).head(6)
for (nombre, fila), desp in zip(top6.iterrows(), desplazamientos):
    ax.annotate(nombre, (fila["saldo_total"], fila["morosidad_pct"]), fontsize=8,
               xytext=desp, textcoords="offset points",
               arrowprops=dict(arrowstyle="-", lw=0.6, color="gray"))
ax.legend(bbox_to_anchor=(1.02, 1), loc="upper left", fontsize=8)
plt.tight_layout()
plt.show()
```

Celda 25: Concentración de la improductiva

Análisis de concentración (tipo Pareto): ordena las entidades por dólares improductivos y calcula el porcentaje acumulado. Contrasta la hipótesis H3.

```
pareto = (ago.groupby("entidad")["improductiva"].sum().sort_values(ascending=False))
pareto_df = pd.DataFrame({"improductiva_musd": pareto / 1e6, "acumulado_pct": pareto.cumsum() / pareto.sum() * 100})
display(pareto_df.head(8).round(1))
print(f"Las 5 primeras entidades concentran {pareto_df['acumulado_pct'].iloc[4]:.1f}% de la cartera improductiva")
```

Celda 26: Cantones con más improductiva

Los 8 cantones con más dólares improductivos (usando solo filas con saldo mínimo, según el paso 5). Muestra dónde está el problema en términos absolutos.

```
cant = analisis[analisis["mes"] == ULT].groupby(["provincia", "canton"])[["saldo_total", "improductiva"]].sum()
cant["morosidad_pct"] = cant["improductiva"] / cant["saldo_total"] * 100
display(cant.sort_values("improductiva", ascending=False).head(8).round(1))
```

Paso 7 · Hallazgos

Celda 27: Hallazgos calculados

Calcula y muestra las conclusiones numéricas a partir de las tablas construidas en los pasos anteriores. Así el texto nunca queda desactualizado respecto a los datos.

```
tot = ago["improductiva"].sum() / ago["saldo_total"].sum() * 100
ene = df[df["mes"] == df["mes"].min()]
tot_ene = ene["improductiva"].sum() / ene["saldo_total"].sum() * 100

print(f"1. Morosidad total banca privada: {tot:.2f}% en {ULT} (enero: {tot_ene:.2f}%).")
top_seg = seg.sort_values("morosidad_pct", ascending=False)
print(f"2. Segmento mas moroso: {top_seg.index[0]} ({top_seg['morosidad_pct'].iloc[0]:.2f}%); "
      f"el menos moroso: {top_seg.index[-1]} ({top_seg['morosidad_pct'].iloc[-1]:.2f}%).")
mayor_usd = seg["improductiva"].idxmax()
print(f"3. En dolares, {mayor_usd} concentra {seg.loc[mayor_usd, 'peso_improductiva_pct']:.1f}% de la improductiva "
      f"(USD {seg.loc[mayor_usd, 'improductiva']/1e6:,.0f} millones).")
print(f"4. Region con mayor tasa: {reg.index[0]} ({reg['morosidad_pct'].iloc[0]:.2f}%, "
      f"pero la region con mas dolares improductivos es {reg['improductiva'].idxmax()}. "
      f"(USD {reg['improductiva'].max()/1e6:,.0f} millones).")
print(f"5. Provincia mas morosa (cartera >= USD 50 millones): {top_prov.index[0]} ({top_prov['morosidad_pct'].iloc[0]:.2f}%).")
print(f"6. Las 5 entidades con mas improductiva concentran {pareto_df['acumulado_pct'].iloc[4]:.1f}% del total; "
      f"la primera es {pareto_df.index[0]}).")
grandes = seg.index[seg["peso_saldo_pct"] >= 1] # se ignoran segmentos con menos de 1% del saldo
sube = cambio.loc[grandes, "var_pp"].sort_values()
print(f"7. Variacion ene-ago (segmentos con >= 1% del saldo): mayor baja en {sube.index[0]} ({sube.iloc[0]:+.2f} pp); "
      f"mayor alza en {sube.index[-1]} ({sube.iloc[-1]:+.2f} pp).")
```

3.1 Script preparar_datos.py

Repite exactamente la limpieza del paso 2 en formato script. Sirve para regenerar el CSV sin abrir el notebook: `python preparar_datos.py`. Lee las hojas BASE de data/raw, consolida duplicados, crea variables derivadas y guarda data/processed/cartera_banca_privada_2026.csv.

3.2 Dashboard (app.py)

Bloque de app.py	Qué hace
cargar_datos() con @st.cache_data	Lee el CSV una sola vez y lo guarda en memoria para que el tablero responda rápido al cambiar filtros.
tasa() y agrupar()	Funciones reutilizables: calculan la morosidad ponderada (suma/suma) y agrupan por cualquier variable.
Filtros en la barra lateral	Periodo, segmento y región filtran los datos. También están las reglas de decisión: umbral de alerta, umbral de oportunidad y cartera mínima.
Cuatro KPIs	Cartera total, cartera improductiva, morosidad ponderada (con variación en puntos porcentuales frente al mes inicial) y segmento más moroso.
Pestaña Resumen	Línea de morosidad por segmento en el tiempo y barras de dólares improductivos por segmento.
Pestaña Geografía	Mapa de calor segmento x región y ranking de provincias más morosas.
Pestaña Entidades	Matriz de riesgo (burbujas) y concentración de la cartera improductiva.
Pestaña Decisiones	Cruza segmento x región y aplica las reglas: alertas (morosidad >= umbral) y oportunidades (morosidad baja y cartera creciendo). Incluye monitoreo de la Costa por El Niño.
Pestaña Datos	Tabla de datos filtrados y botón para descargar el CSV.

4. Parte metodológica: EDA en 7 pasos

El EDA se aplicó como estándar de trabajo. La tabla resume cada paso, qué se hizo y por qué se eligieron esas variables, gráficos y segmentaciones.

Paso	Qué se hizo	Por qué
1 Pregunta	Se definió la decisión (provisiones y colocación), tres hipótesis y la métrica de morosidad ponderada.	Sin una pregunta clara el EDA se vuelve una colección de gráficos sin destino.
2 Estructura	Carga de 4 Excel, unión, tipos de datos, diccionario, controles de cuadre y duplicados, variables derivadas.	Se verifica que los datos sean confiables antes de analizarlos: por vencer + no devenga + vencida cuadra con el saldo total.
3 Univariado	Conteos, descriptivos, histogramas (saldo en escala log), peso de cada segmento, entidades más grandes.	Entender la forma de cada variable: el saldo está muy sesgado y la morosidad tiene picos en 0% y 100%.
4 Bivariado	Morosidad por segmento en el tiempo, mapa segmento x región, saldo vs morosidad, boxplot.	Buscar relaciones entre variables relevantes para la decisión. El gráfico de saldo vs morosidad muestra un embudo que anticipa el problema de los saldos mínimos.
5 Faltantes y atípicos	Nulos, IQR, cuantificación de filas con saldo menor a USD 100 mil, antes y después.	Los atípicos son de tamaño, no de riesgo. Se decide qué hacer y se documenta.
6 Segmentación	Por segmento, región, provincia, entidad (matriz de riesgo y Pareto) y cantón.	El riesgo es desigual. Segmentar permite decidir dónde actuar primero.
7 Hallazgos	Cifras calculadas por código, lectura de hipótesis, decisiones y limitaciones.	Cierra el ciclo: de los datos a la decisión.

4.1 Tratamiento de atípicos (decisión metodológica)

- Los indicadores **agregados** se calculan ponderados con **todos** los datos: los saldos diminutos casi no pesan, así que no distorsionan.
- Los rankings a nivel cantón-entidad usan solo filas con saldo mínimo de USD 100.000.
- No se imputa ningún valor porque no hay nulos reales.
- Se consolidaron 13 duplicados de BP Pichincha en Quito (una fila principal y otra de USD 1) sumando los montos.

4.2 Elección de variables y gráficos


- **Morosidad ponderada:** refleja el riesgo real de la cartera y evita el error de promediar porcentajes.
- **Segmento, región y entidad:** son las tres dimensiones sobre las que un analista de riesgo puede actuar.
- **Escala logarítmica en saldo:** el saldo va de pocos dólares a miles de millones; en escala lineal no se vería nada.
- **Mapa de calor:** permite cruzar dos categorías con una métrica numérica en un solo vistazo.
- **Burbujas por entidad:** combinan tamaño, tasa y dólares improductivos en un solo gráfico.

5. Dashboard y decisiones

Cifras del último corte (2026-08). La morosidad total de la banca privada es **3.10%** (en 2026-01 fue 3.17%). La cartera improductiva suma USD 1,711 millones sobre USD 55.2 mil millones de cartera.


5.1 Por segmento

Segmento	Morosidad	Improductiva	Cartera
Microcrédito	6.38%	USD 250 M	USD 3.92 mil M
Consumo	4.96%	USD 1,100 M	USD 22.18 mil M
Inmobiliario	2.82%	USD 81 M	USD 2.86 mil M
Vivienda interés público	1.34%	USD 1 M	USD 0.07 mil M
Productivo	1.07%	USD 280 M	USD 26.15 mil M




5.2 Por región

Región	Morosidad	Improductiva	Cartera
Oriente	5.65%	USD 34 M	USD 0.60 mil M
Sierra	3.43%	USD 1,058 M	USD 30.84 mil M
Costa	2.61%	USD 618 M	USD 23.67 mil M
Otros	2.38%	USD 0 M	USD 0.00 mil M
Insular	1.83%	USD 1 M	USD 0.07 mil M



5.3 Por entidad

Las cinco entidades con más cartera improductiva concentran **75.5%** del total. La primera es **PICHINCHA** (USD 579 millones), en gran parte por su tamaño.



5.4 Hallazgos y decisiones

- **Provisiones:** Microcrédito tiene la tasa más alta (6.38%), pero Consumo concentra 64.3% de los dólares improductivos. La prioridad de provisiones debe mirar ambos.
- **Región:** la Costa (2.61%) no es más morosa que la Sierra (3.43%). El Oriente tiene la tasa más alta (5.65%) pero con muy pocos dólares.
- **Colocación:** Productivo (1.07%) es el segmento más sano y grande; es candidato a ampliar cartera, revisando región por región en el dashboard.
- **Monitoreo de El Niño:** los datos llegan hasta agosto, antes de cualquier efecto climático. La pestaña Decisiones muestra la evolución de la Costa como línea base para detectar deterioro desde septiembre.
- **Concentración:** 75.5% de la improductiva está en 5 entidades; el análisis de riesgo debe empezar por ellas.

5.5 Limitaciones

- Solo banca privada: no incluye cooperativas ni banca pública.
- No hay datos de provisiones, por lo que no se calcula la cobertura.
- Ocho meses de historia: sirve para tendencia corta, no para estacionalidad anual.
- La morosidad es una definición propia (improductiva / saldo) y puede diferir levemente de la cifra oficial publicada.
- Las asociaciones entre variables no prueban causalidad.

6. Guía de ejecución y publicación

6.1 Ejecutar en el computador

- Instalar Python 3.10 o superior y abrir una terminal en la carpeta del proyecto.
- `pip install -r requirements.txt`
- `streamlit run app.py` abre el dashboard en el navegador.
- Para el notebook: `pip install jupyter` y luego `jupyter notebook`, abrir `notebooks/EDA_cartera_banca_privada.ipynb` y ejecutar todo (Run All).

6.2 Subir a GitHub

- Crear una cuenta en github.com y un repositorio nuevo público, por ejemplo *dashboard-eda-riesgo-credito*.
- Subir todos los archivos del proyecto respetando las carpetas (pestaña Add file > Upload files) o usar git: `git init; git add .; git commit -m "proyecto final"; git remote add origin URL; git push -u origin main`.
- Verificar que estén README.md, requirements.txt, app.py, la carpeta data con los archivos y el notebook.

6.3 Publicar el dashboard (enlace para la entrega)

- Entrar a share.streamlit.io con la cuenta de GitHub.
- Elegir *Create app*, seleccionar el repositorio, la rama *main* y el archivo principal *app.py*.
- Pulsar *Deploy*. En unos minutos aparece la URL pública.
- Pegar esa URL en el README, en la portada de este documento y en la tarea de entrega.

6.4 Qué se entrega y cuándo

Hasta el **viernes 2 de octubre, 23h59**, en la tarea *Proyecto final · Dashboard EDA por profesión*: este documento (PDF), el enlace al repositorio de GitHub y el enlace al dashboard. La exposición es el **sábado 3 de octubre** por Teams, con el dashboard en ejecución.

6.5 Recomendación para el día de la exposición

- Abrir el dashboard, el repositorio y el notebook antes de conectarse. Tener el dashboard local por si falla internet.
- Orden de la presentación: contexto y datos, parte técnica, parte metodológica, dashboard en vivo y decisiones.
- Todos los integrantes deben poder explicar cualquier celda: repasar la sección 3 y las preguntas de la sección 7.

7. Preguntas probables de la exposición

El docente puede pedir «explíquenme esta celda». Estas son preguntas y respuestas cortas para que ambos integrantes practiquen.

¿Por qué usaron solo las hojas BASE?

Porque ya vienen en formato tabla (una fila por entidad, cantón y mes). Las hojas de reporte tienen celdas combinadas y subtotales que duplicarían montos.

¿Qué hace ffill en la carga?

El segmento solo está escrito en la primera fila de cada hoja. ffill copia hacia abajo el último valor no vacío para que todas las filas tengan segmento.

¿Por qué morosidad ponderada?

Porque promediar porcentajes da el mismo peso a un cantón con USD 2 y a uno con miles de millones. Sumar improductiva y dividir entre la suma de saldos respeta el tamaño.

¿Cómo definieron cartera improductiva?

Es la cartera que no devenga intereses más la cartera vencida. Es la definición habitual de cartera problemática.

¿Por qué agruparon los duplicados sumando?

Los duplicados son montos (una fila principal y otra de USD 1 de BP Pichincha en Quito). Como son dólares, se suman.

¿Qué es el IQR y por qué no eliminaron los atípicos?

El rango intercuartílico marca como atípico lo que está fuera de $Q1 - 1,5 IQR$ y $Q3 + 1,5 IQR$. No se eliminaron porque son filas pequeñas que casi no pesan en los agregados; solo se excluyen de rankings por cantón.

¿Por qué escala logarítmica en el saldo?

El saldo va de pocos dólares a miles de millones. Con escala lineal casi todo quedaría pegado a cero.

¿Por qué Spearman y no Pearson?

Spearman trabaja con rangos y no se distorsiona con distribuciones muy sesgadas como la del saldo.

¿Cómo se arma la matriz de riesgo por entidad?

Se agrupa por entidad, se calcula cartera, improductiva y morosidad, se filtran entidades con al menos USD 100 millones y se grafica cartera contra morosidad con el tamaño de la burbuja igual a los dólares improductivos.

¿Qué hace @st.cache_data?

Guarda el resultado de cargar el CSV en memoria para no leerlo de nuevo cada vez que el usuario cambia un filtro.

Si viene El Niño, ¿por qué la Costa no es la más morosa?

Porque los datos son de enero a agosto, antes de que se materialice un efecto climático. Los resultados son una línea base, y el dashboard permite monitorear si la Costa se deteriora en los próximos cortes.

¿Qué limitaciones tiene el análisis?

Solo banca privada, sin provisiones, ocho meses de historia y definición propia de morosidad. Además, correlación no implica causalidad.

¿Los datos son reales?

Sí, son reales, de la Superintendencia de Bancos (Portal Estadístico, Cartera y Depósitos, Año 2026). No se simularon.

Fuentes

Superintendencia de Bancos del Ecuador, Portal Estadístico, Cartera y Depósitos, Año 2026, banca privada (corte agosto 2026). Contexto sobre morosidad y El Niño: prensa económica ecuatoriana, agosto de 2026.